

# Способы кодирования категориальных признаков

- 1) Label / Ordinal encoding: нулевая кодировка признаков.  
Вредный способ, добавляющий метрики для неравным значений признаков
- 2) One-hot encoding: кодирование каждого уникального значения категориального признака отдельными бинарными столбцами. Сильно раздувает кол-во признаков, что плохо сказывается на производительности потому что некоторые алгоритмы умеют работать с разреженными матрицами, но плохо объединяют редкие категории в одну

3) Кодирование с учетом уровня переменных

. Mean target encoding

для бинарной классификации: 
$$g_j(x, X) = \frac{\sum_{i=1}^c [f_j(x) = f_j(x_i)] [y_i = +1]}{\sum_{i=1}^c [f_j(x) = f_j(x_i)]}$$

где  $j$  - индекатор по признаку,  $f_j(x)$  - исходное значение признака у объекта  $x$ ,  $f_j(x_i)$  - значение признака у  $i$ -ого объекта из обучающей выборки  
 $[f_j(x) = f_j(x_i)]$  принадлежит ли  $i$ -ый объект той же категории, что и  $x$

Но на редкие категории получаемся значения левой переменной:  
значение закодированного признака  $\rightarrow 0$  или  $\rightarrow 1$  и в тесте будут  
выбираться не те классы, при объекте с такой же редкой категорией, которую  
на то, что категория не имеет статистической устойчивости.

Как с этим бороться:

Защитное: добавить в итоговый признак penalty

Смягчение: 
$$g_j(x, X) = \lambda \ln(f_j(x)) \frac{\sum_{i=1}^c [f_j(x) = f_j(x_i)] [y_i = +1]}{\sum_{i=1}^c [f_j(x) = f_j(x_i)]} +$$
  
$$+ (1 - \lambda) \ln(f_j(x)) \frac{1}{c} \sum_{i=1}^c [y_i = +1], \text{ где } \lambda(n) - \text{некоторая монотонно}$$
  
возрастающая ф-я  $[0, 1]$  ее значения. Например,  $\text{sigmoid}(n)$ .

Кодирование по времени: кодировка объекта равна среднему значению  
замет для всех предыдущих объектов с той же категорией

параметр  $k$   
$$g_j(x, X) = \frac{\sum_{i=1}^{k-1} [f_j(x) = f_j(x_i)] [y_i = +1]}{\sum_{i=1}^{k-1} [f_j(x) = f_j(x_i)]}$$