

Линейная регрессия.

$$Y = \mathbb{R}$$

① Модель линейной регрессии

$$a(x) = w_0 + \sum_{i=1}^d w_i x_i = w_0 + \langle w, x \rangle$$

свободный коэф. bias веса коэф. модели

$\exists w_k x_i \in X: x_i = 1 \Rightarrow \langle w, x \rangle$

② Область применения: x - квартира в Москве
 y - рыночная стоимость

$$a(x) = w_0 + w_1(\text{площадь}) + w_2(\text{кол-во комнат}) + w_3(\text{расстояние до метро})$$


1) Категориальные признаки

$C = \{C_1, C_n\}$ множество признаков

$b_1(x), \dots, b_n(x)$ - бинарные признаки, где $b_j(x) = [x_j = C_j]$ } one-hot encoding

2) Бинаризация числовых признаков

значен



разбили $\mathbb{R}^1$ на интервалы $[t_i, t_{i+1}]$

$$a(x) = w_1 [t_0 \leq x_1 < t_1] + \dots + w_{n+1} [t_n \leq x_n < t_{n+1}]$$

обучить интервалы нельзя, т.к. не везде можно дифференцировать.

Признаки для линейной модели нужно подбирать осмысленно

③ Измерение ошибки в задаче регрессии

1) $L(y, z) = (y - z)^2$ $MSE(a, X) = \frac{1}{l} \sum_{i=1}^l (a(x_i) - y_i)^2$

среднеквадратичная ошибка будет величиной целевой переменной в квадрате $\Rightarrow$

$$RMSE(a, X) = \sqrt{MSE(a, X)}$$

Коэффициент детерминации: $R^2(a, X) = \frac{\sum_{i=1}^l (a(x_i) - y_i)^2}{\sum_{i=1}^l (y_i - \bar{y})^2} + 1$

$\forall a(x_i) = y_i : R^2 = 1$


$\forall a(x_i) = \bar{y} : R^2 = 0$

$$2) L(y, z) = |y - z| \quad MSE(a, X) = \frac{1}{2} \sum_{i=1}^n |a(x_i) - y_i|$$

y	$a(x)$	$(y - a(x))^2$	$ y - a(x) $
1	2	1	1
1000	2	996004	998
1	1	0	0
1000	3	994009	997

MSE устойчива к выбросам

3) Ф-я Кубьер-а
 $L(y, a) = \begin{cases} \frac{1}{2}(y-a)^2, & |y-a| < 5 \\ 5(|y-a| - \frac{1}{2}5), & |y-a| > 5 \end{cases}$



4) Рассматриваемые ф-ии потерь:

$$MAPE: L(y, z) = \left| \frac{y - z}{y} \right|$$

$$SHAPE: L(y, z) = \frac{2|y - z|}{|y| + |z|}$$

$$5) MSLE: L(y, z) = (\log(z+1) - \log(y+1))^2$$


④ Обучение: $\frac{1}{2} \sum_{i=1}^n (w, x_i - y_i)^2 \rightarrow \min_w$

$$X = \mathbb{R}^{n \times d}, y = \mathbb{R}^n, w = \mathbb{R}^d$$

$$\nabla_w MSE = 0; w = X^+ y \text{ (если } X \text{ полного ранга)}$$

Квадратная матрица получается $O(d^3)$, что очень медленно; поэтому используют градиентный спуск.

⑤ Обобщающая способность модели



Переобучение - ошибки на новых данных больше, чем на обл. выборке

- Обсуждение:
- 1) Атомарная выборка
 X - обуча., X_* - тестовая
 - 2) Кросс-валидация

Доказательство:

представим стоимость квартиры по текстовому описанию. bag of words encoding.

- 1) Пропускаем все слова из выборки текстов $\{C_1, \dots, C_m\}$.
- 2) Закодируем текст n признаками $\{v_1(k), \dots, v_m(k)\}$ - частотой вхождения слов C_i в текст

$\log \cosh(z-y) = L(y, z)$ не имеет разрывов, в отличие от Кубера