

Кросс-валидация

$\square \rightarrow \square + \square + \square + \square + \square$ k -число блоков (folds)

X^k - k -ый блок, X^{-k} - все блоки, кроме k -ого

$$CV = \frac{1}{k} \sum_{k=1}^k Q(a(x, X^{-k}), X^k)$$

обучена на X^{-k}

Leave-one-out

$k=l$

Итоговая модель: 1) обучить на всех данных
2) усреднить прогнозы K моделей

Борьба с переобучением

В примере с полиномом высокого градуса w ; большие (почти всегда) порядки $10^6, 10^4, \dots$

Если модель переобучилась, то, наверняка, её веса большие $\Rightarrow$

необходимо понизить крайнее увеличение весов посредством регуляризации.

$$J_Q(a, X) = MSE(a, X) = Q(a, X) + \lambda \|w\|_2^2 \rightarrow \min_w$$

↑ ↑
коэфф. регуляризации регуляризатор L_2

$$\text{для MSE: } w = (X^T X + \lambda I)^{-1} X^T y$$

Из-за того, что $X^T X$ (матрица Грама) положительно определённая, то добавление $\lambda \cdot I$ сделает её точно невырожденной и, следовательно, обратной.

Полуположительно определенная матрица A : $\vec{v}^T A \vec{v} \geq 0$, где $\vec{v}$ - вектор $[x_1 \times k] [k \times k] [k \times 1]$, размерности $k \times k$
 $A = X^T X \Rightarrow (\vec{X}^T \vec{v})^T \vec{v} = \vec{v}^T X^T X \vec{v} = (X \vec{v})^T \cdot (X \vec{v}) = \|X \vec{v}\|_2^2 \geq 0 \Rightarrow$

$X^T X$ - положительно определена

Чтобы матрица была невырожденной, нужно, чтобы её определитель был не равен 0, следовательно, произведение всех собственных значений $\neq 0$, следовательно, $\forall$ собственное значение $\neq 0$.

$$[(A + I \lambda) v = 0 \Rightarrow A v = -\lambda v \mid \times v^T \Rightarrow v^T A v = v^T v (-\lambda) \geq 0 \Rightarrow \|v\|_2^2 \leq 0 \Rightarrow \|v\|^2 = 0 \Rightarrow v = 0 \Rightarrow \text{Ядро матрицы } X^T X + I \lambda$$

$A v = \mu v; (A + I \lambda) v = \mu_{\lambda} v = A v + \lambda v = (\mu + \lambda) v$ тривиально $\Rightarrow$ обратно
 при обращении $\mu \rightarrow \frac{1}{\mu}$ и веса (малые) увеличатся

В регуляризатор не добавлять свободный член, т.к. при больших значениях целевой переменной смещение будет минимальным и предсказание, соответственно, точнее.

Большие веса imply тем, что при минимальном изменении признака прогноз может очень сильно колебаться

В общем случае эффективность регуляризации не доказана, но она работает.

Как выбирать λ ?

На обучающей выборке подбирать λ бессмысленно, т.к. функционал ошибки будет минимален при $\lambda = 0$ ($\lambda \geq 0$).

Гиперпараметр - нельзя подбирать по обучающей выборке, вводящая для улучшения качества модели на новых данных. Нужно подбирать по

CV или отложенной выборке.

При L_1 регуляризации (+ penalty) часть весов зажимается
 $\lambda \sim$ кол-во 0-ых весов

$\exists$ в X линейно зависимые признаки ($\exists v \neq 0 \forall x \in X: \langle v, x \rangle = 0$)
объект

w_* - лучшие веса по MSE


$$\langle w_* + L v, x \rangle = \langle w_*, x \rangle + \langle L v, x \rangle = \langle w_*, x \rangle + L \cdot 0 \Rightarrow$$

решения не одно; $w_* + L v \xrightarrow{L \rightarrow \infty}$

Обучение линейной регрессии

для MSE: $w = (X^T X)^{-1} X^T y$

Градиентное обучение моделей



1) $w^{(0)}$ - начальное приближение ∇ -пабли

$\nabla_w Q(w)$ - градиент Q по w

$-\nabla Q(w)$ - антиградиент (в сторону скор. убывания)

2) $w^{(k)} = w^{(k-1)} - \nabla Q(w^{(k-1)}) \cdot \eta$ - шаг градиентного спуска

3) когда останавливаться?

— когда ошибка на тесте перестанет быстро убывать

— $\|w^{(k)} - w^{(k-1)}\| < \epsilon$

— $|Q(w^{(k)}, X) - Q(w^{(k-1)}, X)| < \epsilon$

— ...

Сходимость: 1) к $\nabla Q(w) \approx 0$

для линейной модели с матрицей полного ранга
такая точка одна

Если решить несколько, то можно сделать лучше

Улучшения GD:

ошибка градиента


градиентный шаг

Оценивание градиента

$$Q(w, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} (\langle w, x_i \rangle - y_i)^2; \quad Q(w, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} q_i(w)$$

$$\nabla_w Q(w, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} \nabla_w q_i(w)$$

полный градиент



градиент ортогонален линии уровня

$$SGD: \nabla Q(w) \approx \nabla q_i(w); \quad w^{(k)} = w^{(k-1)} - \eta \nabla q_{i_k}(w^{(k-1)})$$

усл. Рунге-Монро

при $\sum_{k=1}^{\infty} \eta_k = \infty, \sum_{k=1}^{\infty} \eta_k^2 < \infty$: SGD всегда сходится

FGD: $Q(w^{(k)}) - Q(w_*) = O(1/k)$	SGD: $O(1/\sqrt{k})$
-------------------------------------	----------------------

Mini-batch GD:

$$\nabla Q(w) \approx \frac{1}{n} \sum_{j=1}^n \nabla q_{i_k j}(w)$$

SAG: $\tilde{z}_i^{(0)} = \nabla q_i(w^{(0)}); k\text{-ая итерация: } \tilde{z}_i^{(k)} = \begin{cases} \nabla q_i(w^{(k-1)}), & i = i_k \\ \tilde{z}_i^{(k-1)}, & \text{иначе} \end{cases}$

$$\nabla Q(w^{(k-1)}) \approx \frac{1}{\ell} \sum_{i=1}^{\ell} \tilde{z}_i^{(k)} \quad O(1/k)$$

Писать значения.

$$f(x): \mathbb{R}^n \rightarrow \mathbb{R}; \nabla_x f(x) = \left(\left(\frac{df}{dx_i} \right)_{i=1}^n \right)^T$$

$$f(A): \mathbb{R}^{n \times n} \rightarrow \mathbb{R}; \nabla_A f(A) = \left(\frac{df}{dA_{ij}} \right)_{i,j=1}^{n,n}$$

$$\text{Задача 1: } x \in \mathbb{R}^n, a \in \mathbb{R}^n, \nabla_x a^T x = ? = \left(\left(\frac{da^T x}{dx_i} \right)_{i=1}^n \right)^T$$

$$\frac{da^T x}{dx_i} = \sum_{j=1}^n \frac{da_j x_j}{dx_i} = 0 + \frac{da_i}{dx_i} a_i = a_i \Rightarrow \nabla_x a^T x = a$$

Теорема Лапласа для разложения определителя по i -ой (столбцу) строке (столбцу).

$$\det X = \sum_k X_{ik} \Delta_{ik} |_i$$

Дифференциал скалярной функции матричного аргумента:

$$df = \text{tr}(Q^T dx) \Rightarrow \nabla_x f = Q$$

Спектральное разложение симметричной матрицы A :

$$A = Q \Lambda Q^T$$

Q - ортогональная матрица собственных векторов ($QQ^T = QQ^T = I = Q^T Q = Q^{-1}$)

Λ - диагональная матрица, на диагонали которой находятся собственные значения

Матрица является ортогональной, если ее строки это нормированные и ортогональные векторы (ортонормированные).

Лагранжиан

Необходимо $\min_x f(x)$ при условии $g(x)$

Условие будет выполняться, когда касательная $g(x)$ будет касаться линии уровня $f(x)$: $\nabla_x f = \lambda \nabla_x g$

лагранжиан: $\mathcal{L}(x, \lambda) = f(x) - g(x) \cdot \lambda$

$$\nabla_x \mathcal{L}(x, \lambda) = \nabla_x f(x) - \lambda \nabla_x g; \quad \frac{\partial \mathcal{L}(x, \lambda)}{\partial \lambda} = -g(x)$$

Приравнявая выражения лагранжиана к 0, находим λ ,
с помощью λ находим x .