


$$J(x, \lambda) = V_x(x) - \lambda V_x g; \quad \frac{\partial J}{\partial \lambda} = -g(x)$$

Приравняем градиент лагранжиана к 0, найдем λ , с помощью λ найдем x .

① Моментум (метод итераций)



$\vec{a}_i$ - градиент на i -ом шаге; по Ox поступательное движение, по Oy график осциллирует, что ухудшает сходимость.

$$h_0 = 0; h_k = \alpha h_{k-1} + \eta \underbrace{\nabla Q(w^{(k-1)})}_{\text{можно заметить на графике}} \quad w^{(k)} = w^{(k-1)} - h_k$$

$$\alpha \in (0; 1)$$

для выпуклого функционала ошибки траектория с методом итераций будет похожа на

② Пусть имеется разреженный признак

x_j - почти на всех объектах 0 $\Rightarrow$ при $x_j = 0$; $\frac{\partial Q}{\partial w_j} = 0 = \frac{\partial Q}{\partial a} \cdot \frac{\partial a}{\partial x_j} = \frac{\partial Q}{\partial a} x_j$
на большинстве итераций не будем менять w_j , и если на 1000-ой итерации $x_j \neq 0$ впервые, то w_j будет всё равно положительным

Т.е. если впервые признак изменится на поздней итерации, то $\nabla_w Q(w)$ будет мал, и за отведённое время признак не успеет обучиться и приблизиться к оптимальному.

Это функция AdaGrad

Ada Grad

$$G_{k,j} = G_{k-1,j} + (\nabla_w Q(\tilde{w}^{(k-1)}))_j^2; \quad W^{(k)} = W^{(k-1)} - \frac{\rho_{k,j}^{const}}{G_{k,j} + \epsilon} (\nabla_w Q(w^{(k-1)}))_j$$

где k - номер итерации, j - номер признака, ϵ - чтобы не поделить на 0

RMS Prop

как Ada Grad, только $G_{k,j} = \alpha G_{k-1,j} + (1-\alpha) (\nabla_w Q(w^{(k-1)}))_j^2$

AdaGrad совмещает два варианта:

Разреженная модель

$$Q(w, X) + \lambda \|w\|_1 \rightarrow \min_w$$

Зачем разреживать модель?


- ускорение
- знаем, что не все признаки полезны
- $\ell < d$ данных меньше, чем признаков

Почему L_1 отбирает признаки?

$$\textcircled{1} Q(w, X) + \lambda \|w\|_1 \rightarrow \min_w$$

$\Leftrightarrow$

$$\begin{cases} Q(w, X) \rightarrow \min_w \\ \|w\|_1 \leq C \end{cases}$$



L_2 будет близка к C , а L_1 равно C

$L_{0.5}$ вероятность касания угла осей.

$w = (1, \varepsilon)$; $\|w - (\delta, 0)\|_2^2 = 1 - 2\delta + \delta^2 + \varepsilon^2$; $\|w - (0, \delta)\|_2^2 = 1 - 2\varepsilon\delta + \delta^2 + \varepsilon^2$
 $0 < \delta < \varepsilon < 1$ $\|w - (\delta, 0)\|_1 = 1 - \delta + \varepsilon$; $\|w - (0, \delta)\|_1 = 1 - \delta + \varepsilon$
 меньше больше

L_2 вынуждает увеличивать большие веса

③ Проксимальные методы

$$S_{\eta L}(w_i) = \begin{cases} w_i - \eta L, & w_i > \eta L \\ 0, & |w_i| \leq \eta L \\ w_i + \eta L, & w_i < -\eta L \end{cases}$$

$$w^{(k)} = S_{\eta L}(w^{(k-1)} - \eta \nabla Q(w^{(k-1)}))$$

Линейная классификация


$X = \mathbb{R}^d$ $Y = \{-1, 1\}$ $y = -1$ отриц. объект
 $y = 1$ поз. объект

$a(x) = \text{sign}(\langle w, x \rangle + w_0)$; если 0 - точка от классификации

$\langle w, x \rangle + w_0 = 0$ - гиперплоскость

$\langle w, x \rangle + w_0 > 0$ и $\langle w, x \rangle + w_0 < 0$

две полуплоскости



④ Обучение линейной классификации

$$Q(a, X) = \frac{1}{2} \sum_{i=1}^l [a(x_i) \neq y_i] \rightarrow \min_a$$

goal function
error rate

$$\frac{1}{2} \sum_{i=1}^l [\text{sign}(\langle w, x_i \rangle) \neq y_i] \rightarrow \min_w \Leftrightarrow \frac{1}{2} \sum_{i=1}^l [y_i \langle w, x_i \rangle < 0] \rightarrow \min_w$$

$M_i = y_i \langle w, x_i \rangle$ - отступ (margin) $|M_i|$ - расстояние от x_i до гиперплоскости

$M_i \ll 0$ - обычно выброс

$$\frac{1}{2} \sum_{i=1}^L [y_i \langle w, x_i \rangle < 0] \quad L(M) = [M < 0]$$



$[M \leq 0] \leq \tilde{L}(M)$
 переобучение шаг назад

$$\frac{1}{2} \sum_{i=1}^L \tilde{L}(M_i) \rightarrow \min_w$$

$$\tilde{L}(M) = e^{-M}, \quad \tilde{L}(M) = \frac{2}{1+e^M}$$

$$\tilde{L}(M) = \log(1+e^{-M})$$

логистический
р-2 потерь

$$\tilde{L}(M) = \max(0, 1-M) - SVM$$

② Метрики качества классификации

1) Для верных ответов (ассимасу) ассимасу $(a, x) = \frac{1}{L} \sum_{i=1}^L [a(x_i) = y_i]$

2)

r_1 улучшить до r_2

r_1	r_2	$r_1 - r_2$	$\frac{r_1 - r_2}{r_1}$
20%	10%	10%	<u>50%</u>
50%	25%	25%	<u>50%</u>
0.1%	0.01%	0.09%	<u>90%</u>