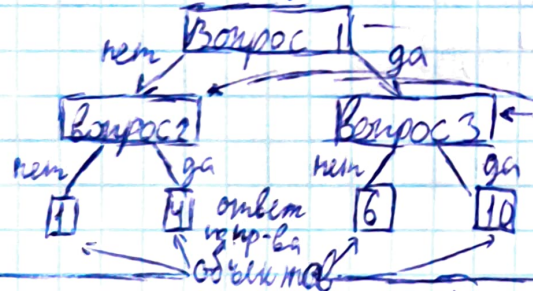
Деревья решений (decision trees)



Дерево решений - бинарное дерево, где:

1) во внутренних вершинах v задан предикат $\beta_v : X \to \{0, 1\}$

2) в каждой листовой вершине v задан прогноз $c_v \in Y$ (как вариант $c_v \in \mathbb{R}^k_+$, $\sum_{k=1}^{K} c_{vk} = 1$)

```
Predict(v, x):
    if v is leaf:
        return c_v
    if β_v(x) == 0:
        return Predict(leftf(v), x)
    else:
        return Predict(right(v), x)
```

Как работает:

С пороговым предикатом можно построить дерево с нулевой ошибкой почти на любой обуч. выборке (только если одинак. объекты не будут иметь разные ЦП)

(риск переобучения)

Параметры деревьев решений

- число вершин
- число потомков у каждой вершины
- предикаты
- прогнозы в листьях

Обучение:

```
FitNode(m, R_m)
    if stop-crit:
        bind c_m
        create leaf's node
        end
```

$j_*, t_* = \arg\max Q(R_m, j, t)$

$R_l = \{(x, y) \in R_m \mid [x_j \geq t]\}$

$R_r = \{(x, y) \in R_m \mid [x_j < t]\}$

FitNode(l, R_l), FitNode(r, R_r)

Критерии останова:

- если достигли макс. глубины
- если $|R_m| < K$
- если ошибка константного прогноза меньше порога
- ...

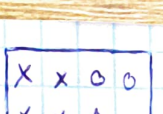
Как находить c_m?

- оптимальный константный прогноз на R_m
- вероятности классов (по доля в R_m)

Как выбрать лучший предикат?

$H(R_m)$ - impurity критерий информативности. Большая, если в R_m большое разнообразие ответов (разнообразие ответов ~ $H(R_m)$)

$H(R) = \min_{c \in Y} \frac{1}{|R|} \sum_{(x,y) \in R} L(y,c)$ — доля



$c = x$ $\quad L(y,c) = [y \neq c]$, $\frac{3}{7} = H(R)$

Регрессия: $L(y,c) = (y-c)^2$, $H(R) = \min_{c \in \mathbb{R}} \frac{1}{|R|} \sum_{(x,y) \in R} (y_i - c)^2 = \frac{1}{|R|} \sum_{(x,y) \in R} (y_i - \bar{y})^2 = Var(y)$

Классификация: ① $L(y,c) = [y \neq c]$ $H(R) = \min_{c \in Y} \frac{1}{|R|} \sum_{(x,y) \in R} [y \neq c] =$ {c - самый популярный класс} =

$$= \left| \begin{array}{l} p_k = \frac{1}{|R|} \sum_{(x,y) \in R} [y = k] \\ k_* - \text{самый популярный класс} \end{array} \right| = 1 - p_{k_*}$$



$H(R)$

$\frac{1}{2}$ хуже

$\frac{1}{2}$

② Критерий Джини (Gini)

$c = (c_1, \dots, c_k)$, $\forall j: c_j \geq 0$, $\sum_{j=1}^{k} c_j = 1$ $\quad H(R) = \min_c \frac{1}{|R|} \sum_{(x_i,y_i) \in R} \sum_{k=1}^{k} (c_k - [y_i = k])^2$

$c_* = (p_1, \dots, p_k)$

$H(R) = \sum_{k=1}^{k} p_k (1 - p_k)$

③ Энтропийный критерий

$$H(R) = \min_c \left(- \frac{1}{|R|} \sum_{(x_i,y_i) \in R} \sum_{k=1}^{k} [y_i = k] \log c_k \right) = - \sum_{k=1}^{k} \log p_k$$

почти то же самое на практике, что и Gini

$= 0$, если только 1 класс

$\to max$, если равномерное распр.

Как выбирать предикаты

$$Q(R_m, j, t) = H(R_m) - \frac{|R_e|}{|R_m|} H(R_e) - \frac{|R_r|}{|R_m|} H(R_r) \to max$$