- Обработка пропусков

Способы: выбор лучшего предиката

перебираем все j и t $[x_j \geq t]$

для части объектов x_j пропущен

зам лучшим предикатом будет объект с неполными пр-опис.

1) скипаем объекты с пропусками для подсчёта Q 2) отправляем в оба поддерева и считаем среднее

применение дерева к новому x

если $[x_j \geq t]$, не знаем x_j; $a_m(x) = \frac{|R_l|}{|R_m|} a_l(x) + \frac{|R_r|}{|R_m|} a_r(x) = \mathbb{E}[a_k(x)]$

Способ 2: Суррогатные предикаты

вершина m, $[x_j \geq t]$; найдем другой признак, дающий наиболее похожее разбиение (получится суррогатный предикат $[x_k \geq \tilde{t}]$)

(Если у объекта пропущен и x_k, то можно отправить объект по наиболее популярному ребру)

② Категориальные признаки

а) число потомков = число уник. значений признака

$Q(R_m) = H(R_m) - \sum_{i=1}^{c} \frac{|R_i|}{|R|} H(R_i)$ быстро растет и переобучается дерево

multi-way splits

б) U - мн-во значений признака j-ого

$\begin{cases} U = U_1 \cup U_2 \\ U_1 \cap U_2 = \varnothing \end{cases}$ $B_j(x) = [x_j \in U_1]$ долго $\begin{matrix} 2^{|U|}-2 \\ \shortparallel \\ 2^{|U|-1}-1 \end{matrix}$ вариантов необх. перебрать U_1, U_2

т.к. симм. разбиения нет смысла р/м

в) бин. классификация

$\frac{1}{N(u_{(1)})} \sum_{x_i \in R(u_{(1)})} [y_i = +1] \leq \ldots \leq \frac{1}{N(u_{(q)})} \sum_{x_i \in R(u_{(q)})} [y_i = +1]$ $R(u_{(1)})$ - объекты из R, у которых $x_j = u_{(1)}$; $N(u_{(1)}) = |R(u_{(1)})|$

доля пол. среди объектов из R, отн. к категории u. $u_{(1)} \to 1$, $u_{(2)} \to 2 \ldots u_{(q)} \to q$ разбиваем как числовой признак (б) = (в)

③ Нейминг

ID3 классиф., энтропийный критерий

C4.5 классиф., Gain Ratio (какая-то нормированная энтропия), сп. обраб. пропусков, стрижка

CART классиф/регр, суррогаты, стрижка
Джини MSE

④ Стрижка деревьев (pruning)

$R(T) + \lambda |T|$

⑤ дерево разбивает пространство на участки с константными ~~предсказания~~ прогнозы w_i

$\mathbb{R}^d = \bigsqcup_{i=1}^n J_i$ $a(x) = \sum_{j=1}^n w_j [x \in J_j]$ линейная модель с нелинейными признаками

Композиции моделей

$X = (x_i, y_i)_{i=1}^{l}$ бутстрап: делаем из X подвыборку размера l с возвращением

$X_1 \quad X_2 \quad \dots \quad X_n$] знаем $p(x)$, $Y \in \mathbb{R}$

$b_1(x) \quad b_2(x) \quad \dots \quad b_n(x)$ $\quad y(x)$ - правильный ответ на X, тогда

$\mathbb{E}_x\Big[\underbrace{(b_j(x) - y(x))}_{\varepsilon_j(x)}^2\Big] = 0$ в среднем $i \neq j$: $\mathbb{E}\, \varepsilon_i(x)\, \varepsilon_j(x) = 0 \Leftrightarrow$

$$\mathrm{Corr}(\varepsilon_i(x), \varepsilon_j(x)) = \mathbb{E}_x[\varepsilon_i(x)\, \varepsilon_j(x)] - \mathbb{E}_x[\varepsilon_i(x)] \cdot \mathbb{E}_x[\varepsilon_j(x)] = 0$$

$$a(x) = \frac{1}{n} \sum_{j=1}^{n} b_j(x)$$

$$\mathbb{E}_x\left[(a(x)-y(x))^2\right]=\mathbb{E}_x\left[\left(\frac{1}{n}\sum\varepsilon_j(x)\right)^2\right]=\frac{1}{n^2}\mathbb{E}_x\left[\|\varepsilon(x)\|_2^2+\sum_{i\ne j}\underset{=0}{\varepsilon_i(x)\varepsilon_j(x)}\right]=$$

$$=\frac{1}{n^2}\mathbb{E}_x\left[\sum_{j=1}^{n}\varepsilon_j^2(x)\right]=\frac{1}{n}\mathbb{E}_x\left[\varepsilon^2(x)\right]$$

детерминированное значение

на конкретной модели в n раз больше была бы ошибка, но моусл. модели несмещенные, не коррелируют друг с другом

Разложение ошибки на смещение и разброс (bias-variance decomposition, BVD)

$X=(x_i,y_i)_{i=1}^{\ell}$, $\mathbb{Y}=\mathbb{R}$ $\quad p(x,y) \quad \mathbb{X}\times\mathbb{Y}$

$\qquad L(y,a) = (y-a)^2$

$$R(a)=\int_{\mathbb{X}}\int_{\mathbb{Y}}p(x,y)(y-a(x))^2\,dy\,dx=\mathbb{E}_{x,y}(y-a(x))^2$$

↑

среднеквадратичный риск.

1) $R(a)=\mathbb{E}_{x,y}(y-\mathbb{E}(y|x))^2+\mathbb{E}_{x,y}(\mathbb{E}(y|x)-a(x))^2$

2) оптимальный алгоритм с точки зрения $R(a)$:

$$a_*(x)=\int_{\mathbb{Y}}y\,p(y|x)\,dy=\mathbb{E}(y|x)$$

$M(X)$ – метод обучения

$M:(\mathbb{X}\times\mathbb{Y})^{\ell}\to\mathbb{A}$ – семейство моделей

$\cancel{L(M)=\mathbb{E}_{x,y}(y-\underset{M(X)(x)}{a(x)})^2}$ $\qquad L(M)=\mathbb{E}_X\mathbb{E}_{x,y}(y-M(X)(x))^2$ – ошибка метод обучения M

Распределение по X: $p(X)=\prod_{i=1}^{\ell}p(x_i,y_i)$

размер выборки ℓ фиксирован

$$L(\mu) = \mathbb{E}_x\Big(\underbrace{\mathbb{E}_{x,y}(y - \mathbb{E}(y|x))^2}_{\text{не зависит от } X} + \mathbb{E}_{x,y}(\mathbb{E}(y|x) - \mu(X)(x))^2\Big)$$

$$\mathbb{E}_{x,y}(y - \mathbb{E}(y|x))^2 + \mathbb{E}_X\mathbb{E}(\mathbb{E}(y|x) - \mathbb{E}_X\mu(X) + \mathbb{E}_X\mu(X) - \mu(X))^2 =$$

$$= \mathbb{E}_{x,y}(y - \mathbb{E}(y|x))^2 + \mathbb{E}_x(\mathbb{E}_X\mu(X) - \mathbb{E}(y|x))^2 + \mathbb{E}_x\mathbb{E}_X(\mu(X) - \mathbb{E}_X\mu(X))^2$$

ошибка лучшей модели

средний прогноз на x всех моделей

отклонение модели на X от средней модели variance