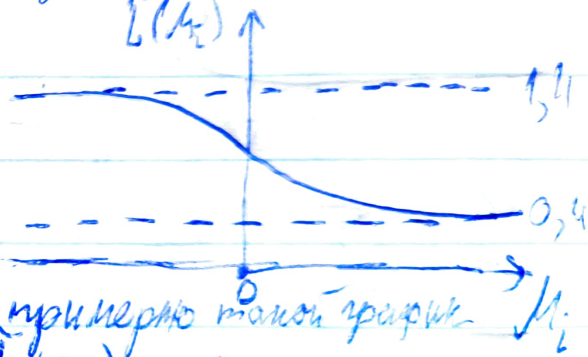
V

№1. $\tilde{L}(\mu_i) = \frac{9}{10} - \frac{1}{\pi}\operatorname{arctg}(\mu_i)$

$\frac{d\tilde{L}(\mu_i)}{d\mu_i} = -\frac{1}{\pi}\cdot(1+\mu_i^2)^{-1}$ дифференцируется на $\mathbb{R}$

$\forall \mu_i: |\operatorname{arctg}(\mu_i)| \leqslant \frac{1}{2}$

$\min\limits_{\mu_i} \tilde{L}(\mu_i) = 0{,}4$; $\max\limits_{\mu_i} \tilde{L}(\mu_i) = 1{,}4$



примерно такой график

$\tilde{L}(0) = \frac{9}{10}$

$\exists L = L[\mu_i < 0] \Rightarrow L(0-) = 1$, $\tilde{L}(0-) = \frac{9}{10}$ $\tilde{L}(\mu_i)$ не верхняя граница

$\tilde{L}(\mu) = 1 \Leftrightarrow -\frac{\pi}{10} = \operatorname{arctg}(\mu_i)$; $\mu = \operatorname{tg}(-\frac{\pi}{10})$

$\tilde{L}(\mu) < L(\mu)$, $\mu \in (\operatorname{tg}(-\frac{\pi}{10}); 0-) \Rightarrow$ это не верхняя граница

№2. $L(y,z) = e^{-yz}$; Если выполнится $\arg\min_z (\mathbb{E}[L(y,z)|x] = P(y=1|x)$, то ~~[illegible]~~ модель обученная на данном лоссе, будет предсказывать корректные вероятности.

z фиксировано, $y \in \{0;1\}$; $\mathbb{E}[L(y,z)|x] = e^{-z} P(y=1|x) + e^{z} P(y=0|x)$

$\frac{\partial \mathbb{E}[L(y,z)|x]}{\partial z} = -e^{-z} P(y=1|x) + e^{z}(1 - P(y=1|x)) = 0$;

$P(y=1|x) = \frac{e^z}{e^z + e^{-z}} = \frac{1}{1+e^{-2z}}$ Модель сигмоида не будет предсказывать корректные вероятности.

№3. $y_i(\langle w, x_i\rangle + b) \geq t \Leftrightarrow y_i(\langle \frac{w}{t}, x_i\rangle + \frac{b}{t}) \geq 1$

$\rho(x_0, a) = \frac{|w^T x + b|}{\|w\|_2} = \frac{\frac{1}{t}|w^T x + b|}{\frac{1}{t}\|w\|_2}$ при фиксированных x_i, y_i расстояние не меняется при $\forall t \Rightarrow$ эти задачи эквивалентны

№ 1) Для вырожденного случая получается, что в силу отсутствия одинаковых объектов с разными тарелками в выборке распределение становится обычной детерминированной ф-ей. Но по факту так может не получиться, если датасет размечали разные разметчики, отличали для одного объекта поставить разные метки, или объекты всё таки отличаются по каким-то признакам, но которые не были выделены людьми, подготавливающими датасет.

2) $\log loss(y,b) = [y=1]\log b + [y=0]\log(1-b)$

$E[\log loss(y,b)|x] = \log b\, P(y=1|x) + \log(1-b)\, P(y=0|x)$; $[p = P(y=1|x)] =$

$E[\log loss(y,b)|x] = \log b\, p + (1-p)\log(1-b)$;

$\frac{\partial E[\log loss(y,b)|x]}{\partial b} = \frac{p}{b} + (-1)\frac{1-p}{1-b} = 0 \;\Big|\cdot b(b-1)(-1)\quad p(1-b) + (1-p)b = 0$

$p = b$; => лог. рег. корректно предсказывает вероятности

3) Как вытекает в 3 пункте, для линейно разделимой выборки справедливо $y_i(\langle w, x_i \rangle + b) \geq t$, $\forall t > 0$; Соотв. мы можем зафиксировать t так, чтобы минимальному ~~расстояние~~ расстояние от точки объекта до разделяющей гиперплоскости соответствовала 1 и тогда всегда найдётся объект x^*, что $y^*(\langle x^*, w \rangle + b) = 1$

№4.
$$\begin{cases} \frac{1}{C}\|w\|_2^2 + \frac{1}{\ell}\sum_{i=1}^{\ell}\xi_i \to \min\limits_{w,b,\xi} \\ \xi_i \geq 0 \\ y_i(w^T x_i + b) \geqslant 1 - \xi_i \\ \min\limits_{x \in X} |\langle w, x\rangle + b| = 1 \end{cases}$$

$\{\xi_i\}_{i=1}^{\ell}$ характеризует штраф за неправильное предсказание. Если модель уверенно предсказала верный класс, то чтобы ξ_i не стало отрицательным и не сделало неравенство более тёжким, $\xi_i = 0$. Необходимость ввода такого штрафа обусловливается тем, что линейной моделью мы не сможем подобрать гиперплоскость, чтобы в линейно неразделимом случае предсказания на всех объектах были правильными $\sum_{i=1}^{\ell}\xi_i = 0$, мы лишь можем минимизировать среднюю ошибку по отступу.

2) $\log loss(y,b) = [y=1]\log b + [y=0]\log(1-b)$

$E[\log loss(y,b)|x] = \log b\, P(y=1|x) + \log(1-b)\, P(y=0|x)$; $[p = P(y=1|x)] =$

$E[\log loss(y,b)|x] = \log b\, p + (1-p)\log(1-b)$;

$\frac{\partial E[\log loss(y,b)|x]}{\partial b} = \frac{p}{b} + (-1)\frac{1-p}{1-b} = 0 \;\Big|\cdot b(b-1)(-1)\quad p(1-b) + (1-p)b = 0$

$p = b$; => лог. рег. корректно предсказывает вероятности

3) Как вытекает в 3 пункте, для линейно разделимой выборки справедливо $y_i(\langle w, x_i \rangle + b) \geq t$, $\forall t > 0$; Соотв. мы можем зафиксировать t так, чтобы минимальному ~~расстояние~~ расстояние от точки объекта до разделяющей гиперплоскости соответствовала 1 и тогда всегда найдётся объект x^*, что $y^*(\langle x^*, w \rangle + b) = 1$

3) $\nabla^2_w = \left(\frac{\partial}{\partial w_k}\left(\frac{\partial Q}{\partial w_j}\right)\right)_{j,k=1}^{d,d} = \left(\frac{\partial^2 Q}{\partial w_k \partial w_j}\right)_{j,k=1}^{d,d}$

$\frac{\partial^2 Q}{\partial w_j \partial w_k} = \frac{1}{\ell}\sum_{i=1}^{\ell} \sigma(M_i)(1-\sigma(M_i)) y_i^2 x_{ik} x_{ij} = \frac{1}{\ell}\sum_{i=1}^{\ell} \sigma(M_i)(1-\sigma(M_i)) \cdot x_{ij} \cdot x_{ik}$

4) $Q(w) \approx Q(0) + w^T \nabla_w Q(0) + w^T \cdot \nabla^2_w(0) \cdot w \cdot \frac{1}{2}$

$Q(0) = \log 2$ $\quad \sigma(0) = \frac{1}{2}$ $\quad \nabla_w Q(0) = -\frac{1}{2\ell}\sum y_i x_{ij} = -\frac{1}{2\ell} X^T y$

$\nabla^2_w(0) = \frac{1}{4\ell}\sum_{i=1}^{\ell} x_{ij} x_{ik} = \frac{1}{4\ell} X^T X$

$Q(w) \approx \log(2) - \frac{1}{2\ell}(X^T y)^T w + \frac{1}{8\ell}\|Xw\|_2^2 =$

$= \log 2 - \frac{1}{2\ell} y^T \cdot Xw + \frac{1}{8\ell}\|Xw\|_2^2$